

Searching Multiple Local Optimal Solutions in Multimodal Function by Bat Algorithm based on Novelty Search

複数解探索におけるノベルティサーチに基づく分散Bat Algorithm

P3-10

○ 岩瀬 拓哉 高野 諒 上野 史 梅内 祐太 石井 晴之 佐藤 寛之 高玉 圭樹 | 電気通信大学

はじめに | 複数解探索の問題点：大域探索と局所探索のバランス

Bat Algorithm(BA)

- ・局所探索性能を自動で調整
- ・ランダムな大域探索Bat Algorithm(BA)

➡ 従来BAでは一つの最良解を探索
局所探索 > 大域探索

目的：分散型BAの提案とその有効性の検証

- ・ノベルティサーチ(大域探索)の導入
- ・複数局所解を保持

従来手法 | Bat Algorithm [Yang X.S., 2010]

Step1: 初期化と解生成

$f_i = f_{min} + (f_{max} - f_{min})\beta \dots (1)$
周波数 f_i の設定 (β は[0 1]の乱数)

$d_i^{t-1} = x_{gbest} - x_i^{t-1} \dots (2)$

$v_i^t = v_i^{t-1} + d_i^{t-1} * f_i \dots (3)$

$x_i^t = x_i^{t-1} + v_i^t \dots (4)$

Step2: 局所探索

If $rand > r_i$

$x_{new} = x_{gbest} + \epsilon A^t \dots (5)$
(ϵ は[-1-1]の乱数)

Step3: ランダムに解生成

ランダムに新しい解 x_{rnd} を生成

Step4: 解とパラメータの更新

If $rand < A_i$ &

$f(x_{gbest}) > \{f(x_i^t), f(x_{new}), f(x_{rnd})\}$

x_i^t, x_{new}, x_{rnd} から x_{gbest} を更新

$A_i^{t+1} = \alpha A_i^t \dots (6)$

$r_i^{t+1} = r_i^t (1 - \exp(-\gamma t)) \dots (7)$


Step1へ戻る ($i = i + 1$ ただし $i = 0$
($i = N$ のとき))

ノベルティサーチ [Joel L, et al, 2008]

k: 個体近傍数 x : 評価される解 μ_i : その他の解

$$\rho(x) = \frac{1}{k} \sum_{i=1}^k distance(x, \mu_i)$$

個体を疎な空間へ移動させる距離関数



提案手法 | Novelty Search Bat Algorithm (NSBA)

変更点1: 全個体から離れるような解生成 (ノベルティサーチの活用)

$$\Rightarrow d_i^{t-1} = \frac{1}{N} \sum_{j=1}^N (x_i^{t-1} - x_j^{t-1}) * \epsilon \left[\frac{\lambda}{|x_i^{t-1} - x_j^{t-1}|} \right] \dots (2)'$$

スカラー→ベクトル式 (探索方向の決定)

個体間の移動距離 (個体同士が近い>遠い)

変更点2: $x_{gbest} \rightarrow x_{pbest}$ に変更


複数局所解探索

$\Rightarrow x_{new} = x_{pbest} + \epsilon A^t \dots (5)'$

パーソナルベスト近辺に新しい解を生成


\Rightarrow If $rand < A_i$ &

$f(x_{pbest}) > \{f(x_i^t), f(x_{new}), f(x_{rnd})\}$
 x_i^t, x_{new}, x_{rnd} から x_{pbest} を更新




問題設定

Griewank関数の概形



Griewank関数の等高線マップ



評価関数: Griewank Function 次元数: 2 範囲: [-10 10]
最適解: $f(x^*) = 0, x^* = (0 \ 0)$ 局所解数: 17

実験内容

BA, NNBA, NSBAの比較

最近傍個体移動Bat Algorithm(NNBA) [岩瀬, 2017]

最近傍個体同士の距離を一定以上保つ

$$d_i^{t-1} = \min(x_i^{t-1} - x_k^{t-1}) \dots (2)'$$

x_k^{t-1} は x_i^{t-1} に最も近い個体

評価指標

各局所解 s_i から最近傍個体までの距離の和

$$dist = \sum_{i=1}^M \min_{j \in N} |s_i - x_j| \quad M \text{は局所解数}$$

パラメータの設定

個体数: $N=20$

世代数: $t=1000$

試行回数: seed=10

ラウドネス: $A^0 = 1$

パルスレート: $r = rand [0 \ 1]$

周波数帯: $f_{min} = 0, f_{max} = 2$


$\alpha = \gamma = 0.9, \quad \epsilon = 1.2, \quad \lambda = 5$

実験結果 | 解の補足数と分布

各手法	解捕捉数	dist	標準偏差
Original BA (従来手法)	1.7 / 17 (10.0%)	141.70	1.059
NNBA (最近傍個体移動)	9.6 / 17 (56.47%)	43.99	1.429
NSBA (全個体分散)	9.1 / 17 (53.53%)	35.92	0.876


10seed分の局所解捕捉数 (N=20)

Original BA
seed=2





一つの局所解に密集

NNBA
seed=2



複数の局所解に分散

NSBA
seed=2



結論 | NSBAの複数解探索性能は、従来BAより大きく向上しNNBAよりも局所探索可能